
UNIVERSIDADE FEDERAL DE OURO PRETO
DEPARTAMENTO DE CIÊNCIA DE COMPUTAÇÃO
PROCESSAMENTO DIGITAL DE IMAGENS

Projeto de Pesquisa

SEGMENTAÇÃO DE LESÃO DE PELE

Alunos:

Caio Monteiro de Oliveira - 20.1.4110,

Lucas Gomes dos Santos - 20.1.4108,

Resumo

Este estudo teve como propósito primordial a criação de um algoritmo avançado destinado à segmentação precisa de lesões cutâneas. Baseando-se no conhecimento adquirido no âmbito da disciplina BCC326 - Processamento de Imagens, o objetivo era desenvolver uma solução eficaz nesse campo. As lesões de pele assumem um papel crucial como indicadores de várias condições médicas, tais como câncer de pele, eczema e acne, desempenhando um papel de destaque nos diagnósticos clínicos. O algoritmo em questão foi minuciosamente concebido e implementado utilizando a linguagem de programação Python, além de valer-se de bibliotecas especializadas em manipulação de imagens. A funcionalidade essencial de convolução foi alcançada através da integração da biblioteca TensorFlow. Notavelmente, a arquitetura Unet foi adotada para o treinamento dos modelos, devido à sua robustez e capacidade de capturar informações contextuais. Os resultados obtidos revelaram a sólida eficácia do algoritmo proposto no delicado processo de segmentação de lesões cutâneas. Seu potencial aplicativo é evidenciado de forma significativa em cenários de diagnósticos médicos, proporcionando informações valiosas aos profissionais da saúde e, consequentemente, aprimorando a qualidade do cuidado clínico prestado.

1 Introdução

Ferimentos na pele são comuns na sociedade brasileira, e esses ferimentos podem ser indicativos de diversas doenças, como câncer de pele, eczema e acne, entre outras, conforme abordado por [Pinheiro \(2018\)](#) em seu artigo. Diante desse contexto, é fundamental realizar um diagnóstico preventivo e monitorar características como tamanho, cor e formato da borda da lesão, a fim de classificá-la corretamente.

No entanto, desafios são enfrentados na classificação precisa das lesões e no treinamento dos profissionais de saúde. Em algumas regiões do Brasil, certos tipos de lesões são mais prevalentes, o que requer uma especialização por parte dos profissionais. Além disso, a interpretação das características de uma lesão de pele pode ser subjetiva, devido a fatores como cor, forma da borda ou tamanho. Profissionais de saúde podem estar fatigados após analisar várias amostras em um único dia, e a iluminação inadequada do local também pode afetar a interpretação.

Diante desse cenário, surgem tecnologias alternativas que auxiliam no diagnóstico e monitoramento de lesões, reduzindo o risco de erros. Uma dessas tecnologias é a segmentação de lesões de pele, que permite classificá-las, registrar suas dimensões e auxiliar os profissionais de saúde na identificação e tratamento. Essa abordagem elimina a necessidade de treinamentos específicos para médicos na identificação de lesões, proporcionando uma solução mais eficiente e acessível.

2 Estado da Arte

2.1 Revisão Bibliográfica

O artigo [Xie et al. \(2020\)](#) ressalta a importância crítica do melanoma, um tipo de câncer de pele, e destaca que a detecção precoce, juntamente com um tratamento adequado, são essenciais para altas taxas de sobrevivência. Segundo o estudo, a dermatoscopia é uma técnica de imagem da pele não invasiva que utiliza luz polarizada para eliminar reflexos da superfície e obter uma visualização mais profunda das estruturas. Essa técnica é bastante útil para os dermatologistas distinguirem entre lesões benignas e malignas, especialmente no diagnóstico do melanoma. A dermatoscopia pode aumentar a precisão diagnóstica em 20 em 100 para comparação com o exame visual a olho nu, embora sua interpretação seja demorada e subjetiva. A segmentação da lesão de pele desempenha

um papel fundamental no diagnóstico assistido por computador na dermatoscopia, pois características cruciais são extraídas das lesões identificadas para discriminar os diferentes tipos de lesões nas etapas subsequentes do diagnóstico. No entanto, os métodos desenvolvidos até o momento têm se baseado principalmente em algoritmos de segmentação convencionais, como limiarização, detecção de bordas e fusão de regiões. Esses métodos dependem de recursos artesanais obtidos a partir de características como cor, textura e forma, tornando sua implementação desafiadora. Neste artigo, é proposta uma arquitetura de rede que consiste principalmente em duas redes convolucionais de camadas 3x3, seguidas por K HRFBs consecutivos como estrutura principal e uma camada convolucional 1x1. Essa abordagem busca melhorar a segmentação e classificação das lesões de pele, contribuindo para um diagnóstico mais preciso e eficiente.

[Burdick et al. \(2018\)](#) também apresenta dados estatísticos, sobre o melanoma, uma forma letal de câncer de pele. Dermatologistas têm desenvolvido diversos métodos para o diagnóstico dessa doença, como o ABCD (Assimetria, Bordas, Cor e Estrutura Diferencial), CASH (Cor, Arquitetura, Simetria e Homogeneidade) e outros. No entanto, estudos têm demonstrado que a eficácia desses algoritmos heurísticos é limitada, o que tem impulsionado o uso de sistemas de diagnóstico assistido por computador, baseados em arquiteturas de Deep Learning. Esses sistemas têm o potencial de aprimorar a precisão e a sensibilidade dos métodos de detecção. Nesse contexto, a segmentação da lesão de pele desempenha um papel fundamental na obtenção de melhores resultados de classificação. O presente artigo enfatiza a importância e o impacto desse processo antes da classificação, dentro do contexto das arquiteturas de deep learning. O método proposto consiste em estender as fronteiras além da lesão, incluindo pixels do fundo, o que pode aprimorar o desempenho de um classificador de lesões de pele em duas categorias (melanoma versus benigna) utilizando uma Rede Neural Convolucional (CNN, do inglês Convolutional Neural Network).

O artigo [Yacin Sikkandar et al. \(2021\)](#), aborda a utilização de imagens não dermatoscópicas para a identificação de melanomas por meio de técnicas computacionais. Enquanto as imagens dermatoscópicas, obtidas em laboratório, geralmente possuem uma iluminação adequada e um contraste melhorado, as imagens não dermatoscópicas possuem a vantagem de serem amplamente disponíveis, embora apresentem iluminação menos uniforme e presença de ruídos. Para realizar a segmentação dessas imagens, o artigo propõe um processo em quatro etapas: 1) pré-processamento, onde são aplicados filtros na imagem para facilitar o reconhecimento de padrões;

2) extração das regiões de interesse a serem analisadas; 3) utilização de uma rede neural para o processamento das informações; 4) pós-processamento dos dados obtidos. Os testes foram realizados em um banco de 126 imagens, das quais 66 continham melanomas e as demais não. A implementação foi realizada utilizando as ferramentas MatLab e Caffe, em um sistema equipado com um processador i7-4790k, 32 GB de RAM e uma placa gráfica NVIDIA GeForce GTX Titan X. Após o pós-processamento, o método apresentou uma eficácia de 98,5 em 100, superando os demais métodos que apresentaram uma média de 95 em 100. Esses resultados destacam a eficácia e o potencial do uso de Deep Learning na segmentação de lesões de pele em imagens clínicas, mesmo considerando as particularidades das imagens não dermatoscópicas. A abordagem proposta no artigo demonstra uma melhora significativa na precisão do processo de segmentação, contribuindo para uma identificação mais precisa de melanomas e possibilitando um diagnóstico precoce e mais efetivo da doença.

Zafar et al. (2020), este artigo apresenta um método automatizado altamente preciso para a segmentação de lesões de pele, com o objetivo de auxiliar no diagnóstico e tratamento rápido de doenças de pele, especialmente o melanoma. Os autores propõem a combinação de duas arquiteturas, a U-Net e a ResNet, que têm mostrado resultados significativos na segmentação de imagens médicas. Inicialmente, as imagens obtidas de conjuntos de dados acessíveis passam por um processo de pré-processamento, que inclui técnicas de redimensionamento, normalização, padronização e remoção de pelos. Em seguida, a rede neural convolucional é treinada com as imagens processadas. Essa arquitetura tem sido amplamente utilizada na assistência de diagnósticos médicos por computador. É importante destacar que foram utilizadas 100 épocas de treinamento e foi aplicado o aumento de dados durante os testes em tempo de execução, com o objetivo de melhorar o desempenho. Aumentar a quantidade de dados aumenta a capacidade do modelo de prever com maior precisão e classificar de maneira mais eficiente. Em resumo, o método utilizado pelos autores mostra um desempenho perfeito na segmentação das lesões, alcançando uma taxa de sucesso de 0,963 na identificação da lesão e das áreas não correspondentes à lesão. No entanto, devido à quantidade limitada de dados disponíveis para o treinamento, foi necessário aumentar significativamente os dados, a fim de evitar o sobreajuste do modelo. Isso significa que o modelo se torna excessivamente familiarizado apenas com os dados previamente observados, mas não consegue produzir resultados precisos para novos dados. Esses resultados ressaltam a eficácia do método

proposto na segmentação de lesões de pele e sua relevância para o diagnóstico precoce e tratamento adequado. No entanto, é importante considerar a necessidade de um conjunto de dados abrangente e diversificado para obter resultados ainda mais robustos e generalizáveis.

Anand et al. (2022) explora a arquitetura U-net para a segmentação de lesões de pele. O modelo proposto foi avaliado no conjunto de dados PH2, que contém 200 imagens de doenças de pele, sendo 160 não melanomas e 40 melanomas. Foi desenvolvida uma versão aprimorada da CNN (Rede Neural Convolutacional), com o objetivo de não apenas identificar se há uma alteração na pele, mas também indicar a área específica afetada. O processo pode ser dividido em dois caminhos principais: o caminho de contração, também conhecido como caminho codificador, e o caminho de expansão simétrica, também conhecido como decodificador. O caminho de contração captura o contexto da imagem, enquanto o caminho de expansão utiliza convoluções transpostas para permitir uma localização mais precisa da lesão. Entre os parâmetros e modelos utilizados no estudo, aquele que apresentou o melhor desempenho alcançou uma precisão de 96,27 em 100 e um índice Jaccard de 96,35 em 100. O coeficiente obtido foi de 89,01 em 100. Os autores acreditam que, apesar desses resultados promissores, ainda há espaço para melhorias adicionais no método. Esses resultados destacam a eficácia do modelo proposto na segmentação de lesões de pele, fornecendo resultados de alta precisão e índices de sobreposição significativos. No entanto, é importante continuar aprimorando e refinando a arquitetura e os parâmetros do modelo, a fim de obter resultados ainda mais precisos e robustos.

Saeed Izadi (2018) o objetivo deste estudo é empregar uma Convolutional Neural Network Densely Connected (DCNN) com um único nó de saída. Os feedbacks gerados por esse nó são subsequentemente utilizados em uma rede Unet, que desempenha o papel de um segmentador. Esta abordagem arquitetural tem como propósito transformar imagens RGB em máscaras de segmentação. O processo de treinamento do modelo envolve uma iteração entre o aprimoramento do segmentador para gerar máscaras mais refinadas e o treinamento da DCNN utilizando essas máscaras segmentadas. A eficácia do modelo foi avaliada utilizando o conjunto de dados DermoFit, que compreende 1300 lesões cutâneas distribuídas em dez categorias distintas. A complexidade desse conjunto de dados apresenta desafios substanciais para a tarefa de segmentação. Para aumentar a diversidade do conjunto de dados, as imagens do banco foram submetidas a transformações como inversões verticais e horizontais, rotações e um conjunto de deformações elásticas. O resultado

qualitativo das segmentações pode ser verificado a baixo:




Figura 1: Avaliação visual das segmentações obtidas.

Os resultados revelaram desempenho comparável a um modelo de última geração e indicaram que a abordagem com um único nó apresenta uma notável melhoria na representação da área interna das lesões.

Wu et al. (2019) apresenta-se um modelo de aprendizado profundo que emprega a arquitetura de rede neural C-Unet para segmentar lesões cutâneas. O treinamento do modelo foi realizado utilizando o conjunto de dados do ISIC 2018. Durante o processo de treinamento, os pesquisadores observaram que a rede tinha uma tendência a identificar áreas mais escuras das lesões, o que afetava a qualidade da segmentação. Para aprimorar o contraste de cores nas imagens, aplicou-se o método de equalização de histograma. Adicionalmente, os autores aprimoraram o desempenho do modelo substituindo o codificador original da Unet por modelos mais sofisticados, como ResNet-10 e VGG. Comparativamente à abordagem convencional com a Unet, a adoção desses modelos

mais complexos permitiu uma extração mais avançada de características em diversas resoluções de imagens. Essa modificação resultou em um modelo de segmentação de lesões cutâneas mais preciso e eficaz. Os testes chegaram a 91.8% de eficácia.

3 Metodologia

O projeto segue uma estrutura de três fases distintas. Na primeira fase, os dados são obtidos a partir do banco de dados do IsicDataChallenge2018. Embora a intenção inicial fosse abordar um conjunto mais abrangente de imagens, as limitações de tempo e recursos computacionais, apesar do apoio de uma GPU, nos levaram a selecionar um conjunto de 1.000 imagens. Como nossa pesquisa envolve não apenas o treinamento, mas também a análise dos dados de treinamento para comparação entre a imagem original, a máscara e a máscara prevista pelo modelo, optamos por limitar o número de imagens usadas para o treinamento a um valor menor (1.000). Isso foi feito para permitir a realização do experimento de maneira eficiente, evitando um tempo excessivo. A fim de garantir imparcialidade, foi utilizado um sorteio para a seleção dessas imagens. Dado esse cenário, a abordagem adotada envolveu o processamento das imagens em diferentes épocas (5, 10, 15 e 20) para permitir uma avaliação comparativa. Para simplificar a análise, optou-se por aplicar essas imagens às Tarefas de Teste 1 e 2, bem como associá-las às máscaras correspondentes à Tarefa de Teste 1. Uma vez que os dados foram coletados, passaram por um processo de tratamento que os preparou para as operações subsequentes.

A subdivisão das imagens e máscaras adquiridas adotou um formato de 60-20-20. Isto é, 60% das imagens foram alocadas para testes posteriores ao treinamento, enquanto 20% foram designadas para validação - uma fase em que o modelo treinado é avaliado e seus hiperparâmetros são ajustados. Os 20% restantes das imagens e suas máscaras correspondentes foram destinados ao próprio processo de treinamento.

Experimentações adicionais foram conduzidas utilizando uma proporção alternativa de divisão: 30-40-40. Nesse arranjo, 30% das imagens foram reservadas para testes após o treinamento, enquanto 40% foram alocadas para a etapa de validação, na qual o modelo treinado é avaliado e refinado por meio de ajustes de hiperparâmetros. Os 40% restantes das imagens e máscaras foram destinados ao processo de treinamento. No entanto, os resultados obtidos com essa proporção

mostraram um desempenho inferior em comparação com a configuração original.

Para o processo de treinamento do algoritmo, o primeiro passo consiste na criação de um diretório denominado "files", destinado a abrigar os resultados gerados ao término do procedimento. Em seguida, são definidos os hiperparâmetros essenciais, como os caminhos de diretórios, o número de épocas (15), entre outros. O passo subsequente envolve a carga dos dados provenientes das imagens previamente processadas. O modelo é então construído e o processo de treinamento é iniciado. Ao finalizar o treinamento, a pasta "files" conterá dois arquivos: "data.csv" e "model.h5". O primeiro arquivo, "data.csv", compreende informações pertinentes, incluindo o coeficiente de dice, a precisão e outros indicadores. Por outro lado, o segundo arquivo, "model.h5", refere-se ao modelo que foi desenvolvido e treinado. Todos esses dados relevantes e resultados serão minuciosamente apresentados na seção denominada 'Resultados'.

A segunda etapa deste projeto engloba a implementação do modelo a ser treinado, utilizando a poderosa biblioteca TensorFlow, juntamente com a arquitetura Unet, esquematizada na figura 1. Essa arquitetura pode ser dividida em duas partes fundamentais. A primeira parte compreende os encoders, os quais consistem em blocos compostos por duas camadas de convolução 2x2, acompanhadas por unidades de ativação ReLU. Tais blocos reduzem progressivamente o tamanho da imagem através de operações de convolução, ao mesmo tempo em que capturam e armazenam suas características através de filtros. É digno de nota que o primeiro encoder recebe a imagem original como entrada, enquanto os subsequentes recebem o resultado de seus predecessores. Da mesma forma, o número de filtros é duplicado a cada etapa, permitindo ao modelo capturar relações mais complexas entre os elementos da imagem. O primeiro bloco, por exemplo, utiliza 64 filtros para representar as características da imagem.

Uma vez finalizada a fase de codificação da imagem, os dados resultantes estão altamente compactados, marcando a transição para a parte final da arquitetura, onde se encontram os decoders. Nesta etapa, a segmentação real da imagem ocorre. Isso é essencial, uma vez que os dados obtidos durante a fase de encoding não contêm informações sobre a localização ou área dos objetos identificados na imagem original. Uma contribuição vital nessa etapa é a presença de conexões entre os encoders e decoders do mesmo nível, chamadas de pontes. Essas pontes permitem que os feature maps dos encoders sejam concatenados com as convoluções transpostas dos decoders do mesmo nível. Essa estratégia visa enriquecer os feature maps previstos pelos decoders durante a

decodificação.

A medida que os níveis dos decoders aumentam, a imagem é gradualmente expandida até atingir o tamanho original, graças ao uso de operações de desconvolução. Para o resultado final, foi determinado que o tamanho do padding deveria permanecer idêntico ao da imagem original. Assim, o tamanho do resultado é igual ao da imagem de entrada, evitando que a imagem final tenha dimensões reduzidas.

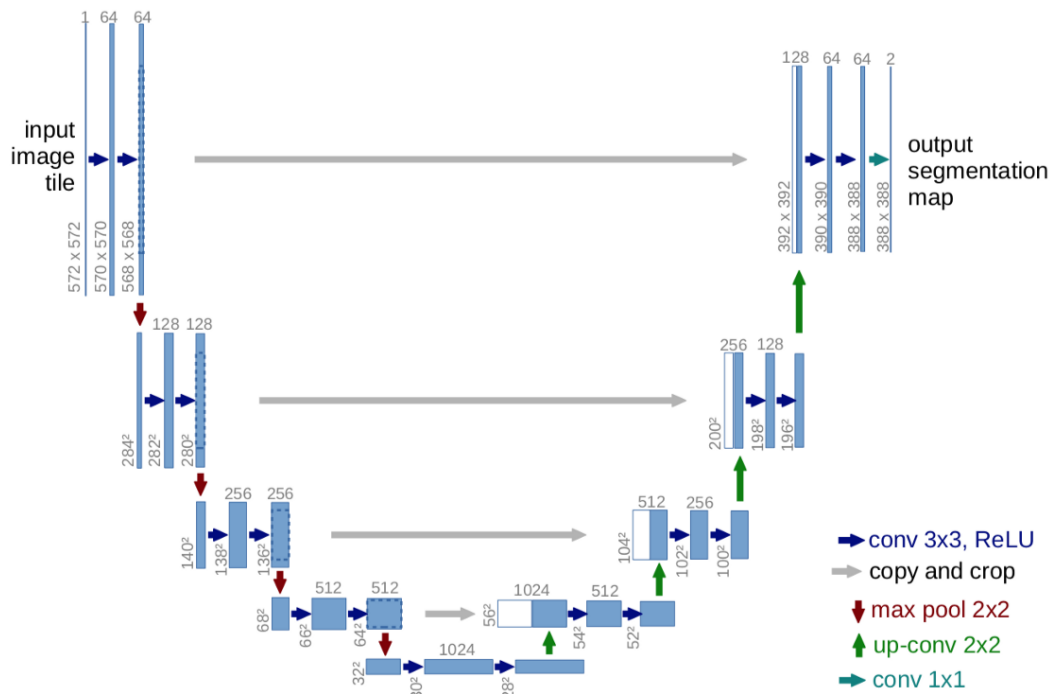


Figura 2: Arquitetura Unet.

A terceira e última fase do projeto representa o estágio em que o modelo treinado é carregado e as funções cruciais para realizar a comparação entre a máscara prevista pelo modelo e a máscara original do conjunto de dados entram em ação. Nesse sentido, os resultados obtidos durante essa etapa fundamental foram cuidadosamente documentados e apresentados na seção intitulada 'Resultados'. Essa seção contém as avaliações quantitativas e qualitativas que fornecem informações detalhadas sobre a eficácia do modelo, destacando sua capacidade de realizar a segmentação precisa das lesões cutâneas.

4 Resultados

No que diz respeito aos resultados, é viável segmentá-los em duas fases claramente definidas. A primeira dessas fases é dedicada ao treinamento do algoritmo, sendo essencialmente o passo precursor da subsequente geração de imagens segmentadas. Essa fase de treinamento, envolvendo um elemento central do processo, demandou aproximadamente 40 minutos para ser concluída. Notavelmente, esse treinamento foi conduzido aproveitando o poder de processamento de uma GPU externa, fazendo uso da plataforma Google Colab para a execução.

A tabela a seguir apresenta os dados extraídos do arquivo "data.csv" após a conclusão do processo de treinamento. Os valores correspondem a cada época do treinamento, destacando-se que a análise se baseia no caso mais bem-sucedido testado. É relevante mencionar que foram conduzidos outros experimentos que resultaram em desempenho menos satisfatório:

A	B	C	D	E	F	G	H	I	J	K	L
epoch	dice_coef	iou	loss	lr	precision	recall	val_dice_coef	val_iou	val_loss	val_precision	val_recall
0	0.3765491843223572	0.23589858412742615	0.7536855936050415	1.00E-04	0.31976133584976196	0.5494036674499512	0.3307546377182007	0.2015714794397354	0.6805920600891113	0.1678403913974762	0.03138676658272743
1	0.35612693428993225	0.2193550318479538	0.5971497893333435	1.00E-04	0.4870471954345703	0.2722225487232208	0.31683221459388733	0.19098903238773346	0.6356916427612305	0.03026091866195202	0.0008222120814025402
2	0.3501272201538086	0.2142326564788818	0.5567383766174316	1.00E-04	0.5552202463150024	0.20228717309039255	0.29984790086746216	0.1784721314907074	0.6030921936035156	0.02801600196957588	0.0001886472946260422
3	0.3671154379846655	0.268277108669281	0.5339673757553101	1.00E-04	0.57364323267593384	0.24644863605499268	0.3389371931552887	0.20724336802959442	0.6231591701507568	0.3818911015987396	0.2910154163837433
4	0.41787803173065186	0.2667997381415558	0.4924086332321167	1.00E-04	0.58534122124822998	0.4528501031782959	0.40553268790245056	0.26058948040008545	0.9264591336250305	0.3032488226890564	0.928841925999268

Figura 3: Conteúdo do arquivo "data.csv" com 5 epochs.

A	B	C	D	E	F	G	H	I	J	K	L
epoch	dice_coef	iou	loss	lr	precision_2	recall_2	val_dice_coef	val_iou	val_loss	val_precision_2	val_recall_2
0	0.37695398926734924	0.23605318367481232	0.7224060893058777	0.0001	0.34467002749443054	0.49020761251449585	0.33445462584495544	0.20435293018817002	0.6837098598480225	0.332207590341568	0.4616427421569824
1	0.35347920656204224	0.21684569120407104	0.5812518000602722	0.0001	0.5107527375221252	0.24385373294353485	0.31959816813468933	0.1931469887495041	0.6429062485694885	0.26271870732307434	0.0007458340842276812
2	0.39211753010749817	0.24616539478302002	0.5237807631492615	0.0001	0.5646092295646667	0.360916405916214	0.32682210206985474	0.1976274698972702	0.5671965479850769	0.24702773988246918	0.054146746871993e-05
3	0.4537416696548462	0.29624709469691365	0.47018763422966003	0.0001	0.615558313369751	0.5558122396469116	0.4510048184394836	0.29733216762542725	0.7543565630912781	0.39975905418395996	0.8611987629208374
4	0.47694736289979	0.31571913595199505	0.4493730962276459	0.0001	0.6477265954017639	0.5675903559371079	0.43707739436148597	0.28842765029284973	1.191711902184082	0.3003351984082336	0.978021502484812
5	0.49300169947631804	0.330103576183391	0.43366011977119574	0.0001	0.6741862893104553	0.57890457854270935	0.4360385835170746	0.28696370124816895	1.1379566192626953	0.307223081587451	0.97214800111940002
6	0.499969849680072	0.336353318042755	0.4310784935951233	0.0001	0.6772026419639587	0.5739594868091614	0.4361036717891693	0.2876021564008054	1.4615784883499146	0.2932789627854	0.980730772184326
7	0.5074701905250549	0.3428218960762024	0.4219614267349243	0.0001	0.6902374625205994	0.57348112425209045	0.43236470222473145	0.2840879595916907	1.2557023763656616	0.2952159643173218	0.9799249172210693
8	0.521072030674438	0.3550210592117096	0.3999910911125183	1E-05	0.726273897953996	0.5653698248901978	0.44807302951812744	0.29646825790405273	0.9530129432676223	0.33583475818634033	0.9416630079460144
9	0.5369297106742859	0.37158171532267761	0.386597723388672	1E-05	0.7294120192527771	0.6171838645120239	0.45537978410720825	0.3012780249118805	0.7415372729301453	0.38612470030794607	0.8865607557296753

Figura 4: Conteúdo do arquivo "data10.csv".

A	B	C	D	E	F	G	H	I	J	K	L
epoch	dice_coef	iou	loss	lr	precision_3	recall_3	val_dice_coef	val_iou	val_loss	val_precision_3	val_recall_3
0	0.37136349081993103	0.23098920285701752	0.6528708934783936	0.0001	0.37853196263313293	0.38860732316970825	0.3264264762401581	0.19826550781726837	0.6644313335418701	0.03227245488864369	2.0817313270526938e-05
1	0.3925815224647522	0.24666456878185272	0.5432417392730713	0.0001	0.5493053793907166	0.34526175260543823	0.36432892084121704	0.2261008620262146	0.6067835688951003	0.47473856806755066	0.7457292675971985
2	0.458589713668823	0.3003493712673187	0.472896246255493	0.0001	0.612214279174805	0.5767218470573425	0.45531710982322893	0.302114158687897	0.979237847328186	0.3423119173550415	0.904747128486333
3	0.4913865923881531	0.32829704880714417	0.44270360469818115	0.0001	0.670578122139877	0.57385748624881104	0.45222246646881104	0.3003469407558441	1.3663824796676636	0.3134637475013733	0.93238031084166206
4	0.5055685639381409	0.3409763276576996	0.42758142948150638	0.0001	0.6854798197746277	0.567300200669881	0.4411979913711548	0.28964462876319885	0.9240139126777649	0.33247360587120506	0.8954818844795227
5	0.513123933601379	0.3477844297885895	0.41866177320480347	0.0001	0.6902868781089783	0.5628039836883545	0.4354044795036316	0.2843862473964691	0.8131585717201233	0.33841845393180847	0.8864807486534119
6	0.5229026675234304	0.35683417320251465	0.41164305806159973	0.0001	0.7086126804351807	0.5737369906516357	0.43838006258010864	0.2876594662666321	0.9547063708305359	0.32066798210144043	0.923362135887146
7	0.52401737213348	0.356731861829757	0.39618977904319768	1E-05	0.743811945779419	0.5449233651161194	0.4203615188598633	0.2714896500110626	0.739590906143188	0.3517935574054718	0.8729286798894104
8	0.5393694043159485	0.3719448745250702	0.3847224712371826	1E-05	0.738655686378479	0.5956984758377075	0.4253239929676056	0.27573153376579285	0.7695102095603943	0.344277693271637	0.8816499710083008
9	0.549644947052002	0.38184264302253723	0.37871378660202028	1E-05	0.7388050556182861	0.6177993416786194	0.43116922186447144	0.2803970575326416	0.7678227424621582	0.349036306142807	0.8689478039741516
10	0.5580114722251892	0.3899817168712616	0.37303152680397034	1E-05	0.7414255142211914	0.632378339767456	0.4386468529701233	0.28623631596565247	0.7363009452819824	0.3646523952484131	0.838920720756531
11	0.5614637374077793	0.3879613184928994	0.36704039573869434	1E-05	0.7455035448074341	0.6436364650726318	0.44497083650531146	0.2911006080280945	0.696178674697876	0.38465379009246828	0.7994751324138069
12	0.57641304497406	0.40815916657447815	0.3566238284111023	1E-06	0.757004976272583	0.6580066105967031	0.4552513062952049	0.2988415982427321	0.6124077914810181	0.43213777773742676	0.7216195464134216
13	0.5780174732208252	0.40977615118026733	0.3549315929412842	1E-06	0.7592450380325317	0.6608227491378784	0.4639292657375357	0.30568045377731323	0.5632014274597168	0.47528135776519775	0.6694567799568176
14	0.5794743895530701	0.4112449586391449	0.353736013174057	1E-06	0.7601503137373804	0.6633173823356628	0.47082018852233887	0.3113088309764862	0.5368781685829163	0.5070117712020874	0.6399382112602234

Figura 5: Conteúdo do arquivo "data15.csv".

A	B	C	D	E	F	G	H	I	J	K	L
epoch	dice_coef	iou	loss	lr	precision_4	recall_4	val_dice_coef	val_iou	val_loss	val_precision_4	val_recall_4
0.0	374377965927124	0.23268631100654602	0.5748058557510376	0.0001	0.46424853801727295	0.3343486487865448	0.3239755630493164	0.19638989865779877	0.6531879901885986	0.0	0.0
10.0	473404198884964	0.3129046559333801	0.4697537124156952	0.0001	0.6258379220962524	0.5982708930969238	0.3906567394733429	0.2486264407634735	0.8724128007888794	0.27713924646377563	0.9920027256011963
20.0	5014255046844482	0.337360382080781	0.49944409489631653	0.0001	0.6767398118972778	0.5764045175332031	0.4190215766429901	0.2737247347831726	1.9077744483947754	0.2688494324684143	0.9981915950775146
30.0	5134173631668091	0.3480854034423828	0.42373302578926086	0.0001	0.6974009275436401	0.5652041435241699	0.42236965894699097	0.2764703929424286	1.8870630264282227	0.2714278995990753	0.99645238502405
40.0	5218356847763062	0.3559298813343048	0.41379305720329285	0.0001	0.7035661935806274	0.57068872451782230	0.42393505573272705	0.2776544392108917	1.7209672927856445	0.2746197581291199	0.9936234354972839
50.0	5299745202064514	0.3634856343269348	0.40620681643486023	0.0001	0.7118269801139832	0.5793843269348145	0.425047367811203	0.2784665524959564	1.6147429943084717	0.2770484983921051	0.9913602471351624
60.0	5433478355407715	0.3757973611354828	0.3807814419269562	1E-05	0.7522960305213928	0.5910887718200684	0.4242832064628601	0.27727583050727844	1.2845927476882935	0.28365471959114075	0.9849312901496887
70.0	5631293654441833	0.395026296377182	0.3672192692756653	1E-05	0.7542451620101929	0.6370300650596619	0.4237476587295532	0.276630163192749	1.2449734210968018	0.2858845889568329	0.9813424944877625
80.0	5781986713409424	0.4099197685718536	0.35795891284942627	1E-05	0.7557590007781982	0.6559128165245056	0.42365413904190063	0.2765430510044098	1.284439206123352	0.28644633293151855	0.978910277484131
90.0	58998185634613	0.4218435287475586	0.3493020236492157	1E-05	0.7618591785430908	0.6684409976005554	0.42485296726226807	0.2775104343891144	1.3167939186096191	0.28913629055023193	0.9722909927368164
100.0	601513147354126	0.4336861670017242	0.3396950662136078	1E-05	0.7714828252792358	0.6789560914039612	0.42780961793899536	0.2798771560192108	1.2958942651748657	0.29557037353515625	0.9542104005813599
110.0	614939803108215	0.447551429271698	0.3235296905040741	1E-06	0.7925305962562561	0.6935037970542908	0.43651673197746277	0.28614342212677	1.0427528619766235	0.3240298926830292	0.8792469501495361
120.0	6179772019386292	0.4507889449596405	0.3210015594959259	1E-06	0.79371577501297	0.6977924108505249	0.4486948847770691	0.295257031917572	0.831653833892822	0.3688797950744629	0.7901070713996887
130.0	620438933724976	0.4534197151660919	0.3191361129283905	1E-06	0.7946904301643372	0.7008899450302124	0.4586571156978607	0.3027958571910858	0.7042005062103271	0.4150262475013733	0.7165094017982483
140.0	6226590275764465	0.4557978808879852	0.31751006841659546	1E-06	0.7955458760261536	0.7035648226737976	0.4647606611251831	0.3074532747268677	0.6363344192504883	0.45012786984443665	0.6619253754615784
150.0	6247380971908569	0.4580304026603699	0.31599438190460205	1E-06	0.7964552640914917	0.7059361338615417	0.46844956278800964	0.3103325366973877	0.6020570993423462	0.47526416182518005	0.6276533603668213
160.0	6267183423042297	0.4601617455482483	0.3145390450954437	1E-06	0.7973933815956116	0.7080531120300293	0.4706178307533264	0.31205978989601135	0.5850667357444763	0.4913614094257355	0.6065460443496704
170.0	628619372844696	0.4622130692005157	0.3131255805492401	1E-06	0.7983959913253784	0.7100192904472351	0.4719114601612091	0.31310582160949707	0.5766420364379883	0.5014933347702026	0.5923900785064697
180.0	630453884601593	0.4641973078250895	0.3117411344650421	1E-06	0.799413800239563	0.7119560837745667	0.47266727685928345	0.3137229084968567	0.5725538730621338	0.5076568722724915	0.5839943885803223
190.0	6322312951087952	0.4661244451999664	0.31037968397140503	1E-06	0.8004472255706787	0.713732123374939	0.473084956407547	0.3140672445297241	0.5707504749298096	0.5113193392753601	0.5779964327812195

Figura 6: Conteúdo do arquivo "data20.csv".

4.1 Pós treinamento

Após a conclusão do treinamento e a organização completa dos dados na pasta "files", é possível prosseguir para a segunda fase. Isso envolve a execução do arquivo "eval.py", que consome os dados gerados durante o treinamento e gera um conjunto de imagens segmentadas. O formato dessas imagens é composto por três elementos sequenciais: a imagem original, a máscara original e, por último, a máscara prevista pelo modelo.

Abaixo está ilustrado um exemplo concreto de uma imagem gerada por meio desse algoritmo:




Figura 7: Exemplo de imagem gerada pelo algoritmo nos estágios iniciais do treinamento.




Figura 8: Exemplo de imagem gerada pelo algoritmo nos estágios finais do treinamento.

5 Conclusão

Esta pesquisa se concentrou no desenvolvimento de algoritmos para segmentação de lesões de pele usando redes neurais convolucionais. O desenvolvimento desse algoritmo foi feito em resposta à dificuldade do diagnóstico de doenças de pele, como câncer de pele, eczema e acne, indicadas por lesões de pele. A importância da detecção precoce e do tratamento adequado é fundamental para a saúde do paciente, e o uso da tecnologia de processamento de imagem e aprendizado de máquina pode melhorar muito esse processo.

Ao longo deste estudo, exploramos a literatura existente sobre a segmentação de lesões de pele, examinando diversas abordagens e arquiteturas de redes neurais convolucionais utilizadas para esse propósito. Essa revisão mostrou a crescente importância dessas técnicas na medicina, particularmente na dermatologia, e a capacidade das redes neurais convolucionais em capturar informações contextuais e realizar tarefas de segmentação com alta precisão.

Nosso trabalho culminou na implementação de um algoritmo de segmentação de lesões de pele baseado na arquitetura Unet. Utilizamos um conjunto de dados diversificado para treinamento e validação, ajustando hiperparâmetros e refinando o modelo para obter resultados otimizados. Os resultados obtidos demonstraram a eficácia do algoritmo proposto na segmentação precisa das lesões, com taxas de sucesso consistentes e alta sobreposição com as máscaras originais das lesões.

Em resumo, este estudo contribui para a área de diagnóstico assistido por computador em dermatologia, oferecendo uma abordagem inovadora para a segmentação de lesões cutâneas. A implementação do algoritmo demonstrou seu potencial em fornecer informações valiosas para os profissionais de saúde, melhorando a qualidade do atendimento clínico e contribuindo para a detec-

ção precoce e tratamento eficaz de doenças de pele. À medida que as tecnologias de aprendizado de máquina continuam a evoluir, a integração dessas abordagens na prática médica pode se tornar ainda mais relevante e benéfica no futuro.

Referências

- Anand, V., Gupta, S., Koundal, D., Nayak, S. R., Barsocchi, P., & Bhoi, A. K. (2022). Modified u-net architecture for segmentation of skin lesion. *Sensors*, 22(3), 867. (Accessed: 2023-06-24)
- Burdick, J., Marques, O., Weinthal, J., & Furht, B. (2018). Rethinking skin lesion segmentation in a convolutional classifier. *Journal of digital imaging*, 31(4), 435–440. (Accessed: 2023-06-23)
- Pinheiro, C. (2018). *As doenças de pele que mais abalam o bem-estar*. Retrieved from <https://saude.abril.com.br/medicina/doencas-de-pele-abalam-a-mente/> (Accessed: 2023-06-23)
- Saeed Izadi, J. K. e. G. H., Zahra Mirikharaji. (2018). Generative adversarial networks to segment skin lesions. (Accessed: 2023-08-02)
- Wu, J., Chen, E. Z., Rong, R., Li, X., Xu, D., & Jiang, H. (2019). Skin lesion segmentation with c-unet. , 2785-2788. (Accessed: 2023-08-02)
- Xie, F., Yang, J., Liu, J., Jiang, Z., Zheng, Y., & Wang, Y. (2020). Skin lesion segmentation using high-resolution convolutional neural network. *Computer methods and programs in biomedicine*, 186, 105241. (Accessed: 2023-06-24)
- Yacin Sikkandar, M., Alrasheadi, B. A., Prakash, N., Hemalakshmi, G., Mohanarathinam, A., & Shankar, K. (2021). Deep learning based an automated skin lesion segmentation and intelligent classification model. *Journal of ambient intelligence and humanized computing*, 12, 3245–3255. (Accessed: 2023-06-29)
- Zafar, K., Gilani, S. O., Waris, A., Ahmed, A., Jamil, M., Khan, M. N., & Sohail Kashif, A.

(2020). Skin lesion segmentation from dermoscopic images using convolutional neural network. *Sensors*, 20(6), 1601. (Accessed: 2023-06-29)